

NYC Yellow Taxi Trip Data

Lucas Hemerly

2026-09-17

Table of contents

Projeto de Engenharia de Dados: ETL Simples com Dados de Táxi de Nova York	1
1. Resumo do Projeto	1
2. Estrutura e Links	2
2. Fluxo do Pipeline (Step by Step):	4
2.1 Extração dos dados	4
2.2 Verificação de qualidade e detecção de anomalias	4
2.3 Transformação e criação de colunas analíticas	5
2.4 Agregações e métricas de negócio	5
2.5 Carregamento da camada limpa	5
2.6 Visualização e interpretação dos resultados	6
3. Dashboard:	6
4. Conclusão	9

Projeto de Engenharia de Dados: ETL Simples com Dados de Táxi de Nova York

1. Resumo do Projeto

- **Objetivo:** Este projeto teve como objetivo construir um pipeline ELT simples utilizando dados de viagens de táxi em Nova York. O foco foi entender o fluxo completo de ELT na prática, desde a extração de dados brutos até a análise de Business Intelligence (BI) com visualizações interativas.
- **Problema Resolvido:** O dataset bruto continha volumes inviáveis para processamento leve em máquina local, além de apresentar diversas inconsistências e anomalias nos dados (distâncias zeradas com cobrança, tarifas negativas e registros fora do escopo temporal), foi criada uma rotina de limpeza e tratamento do dado, validação rigorosa de regras de negócio.
- **Tecnologias Utilizadas:** O dataset disponibilizado no Kaggle, Python, Pandas, Streamlit, Quadro, Figma e Git/GitHub.
- **Resultados Principais:**

- Ingestão controlada de uma amostra de 500.000 registros do NYC Yellow Taxi Trip Data.
- Redução de 11,91% da base resultando em uma camada analítica limpa de 440.450 linhas.
- Dashboard interativo com métricas de tempo médio de corrida, distribuição de receita por zona e impacto das gorjetas.

2. Estrutura e Links




Figure 1: Desenho da Estrutura

Dataset: NYC Yellow Taxi

Kaggle: [Link](#)

GitHub: [Lucas-Lellis-NYC-Yellow-Taxi-Trip-Data](#)

A seguir, estão visualizações reais do arquivo parquet produzido no processo de ETL.

Table 1: Métricas principais do dataset limpo

	Métrica	Valor
0	Total de viagens	440,458
1	Distância média (milhas)	2.88
2	Tarifa média	\$12.54
3	Duração média (min)	15.48
4	Gorjeta média	\$1.83
5	Receita total	\$6,972,263.99




Figure 2: Volume de viagens por hora do dia




Figure 3: Média da tarifa por dia da semana




Figure 4: Distribuição do tipo de pagamento

2. Fluxo do Pipeline (Step by Step):

2.1 Extração dos dados

- O processo começou com a leitura do arquivo CSV `yellow_tripdata_2016-03.csv` utilizando a biblioteca Pandas.
- Foi carregada uma amostra de 500 mil registros para facilitar a análise local e reduzir o custo computacional.
- A etapa inicial também incluiu validação básica da estrutura do dataset, como quantidade de linhas, colunas e visualização dos primeiros registros.
- Com isso, foi possível confirmar que a base estava em um formato adequado para o início do pipeline.

2.2 Verificação de qualidade e detecção de anomalias

- As colunas de data foram convertidas para o tipo `datetime` para permitir cálculos de tempo e filtros mais robustos.
- Foi feita a checagem de valores nulos para identificar problemas de integridade dos dados.
- Em seguida, regras de negócio foram aplicadas para detectar registros inválidos, como:
 - passageiros fora do intervalo aceitável;
 - distância de viagem zerada ou muito alta;
 - `RatecodeID` fora do padrão;

- gorjetas negativas;
 - duração de viagem inconsistente;
 - coordenadas fora da região de Nova York.
- Todos esses registros foram marcados em uma máscara e removidos da base para evitar distorções na análise.

2.3 Transformação e criação de colunas analíticas

- A base foi tratada para gerar novas variáveis que ampliam o valor analítico do conjunto:
 - trip_duration_min: duração total da viagem em minutos;
 - hour_of_day: hora da coleta da viagem;
 - date: data da corrida;
 - day_of_week: dia da semana;
 - trip_speed_mph: velocidade média da viagem;
 - tip_pct: percentual de gorjeta;
 - revenue_per_mile: receita por milha.
- Essas variáveis permitem responder perguntas mais relevantes de negócio, como horários de pico, desempenho por dia e padrão de cobrança.

2.4 Agregações e métricas de negócio

- A base tratada foi agregada por diferentes dimensões para gerar indicadores de negócio:
 - por hora do dia;
 - por dia da semana;
 - por tipo de pagamento;
 - por fornecedor (VendorID).
- Os resultados foram organizados em tabelas que resumem métricas como:
 - total de viagens;
 - distância média;
 - tarifa média;
 - duração média;
 - gorjeta média;
 - receita total.
- Essas agregações servem como base para a análise exploratória e para a construção dos gráficos do dashboard.

2.5 Carregamento da camada limpa

- A base final já tratada foi salva em formato Parquet no diretório de saída:
 - ../data/output/yellow_tripdata_2016-03_cleaned.parquet

- O parquet foi escolhido por ser um formato mais eficiente para armazenar dados tabulares em pipelines de análise.
- A etapa final garante que a camada limpa fique disponível para reutilização em relatórios, dashboards e novas análises futuras.

2.6 Visualização e interpretação dos resultados

- Os dados limpos foram utilizados para criar visualizações de:
 - volume de viagens por hora;
 - tarifa média por dia da semana;
 - distribuição de formas de pagamento;
 - métricas principais do conjunto.
- Essas visualizações transformam o banco em informações estratégicas e ajudam a comunicar os achados de forma clara para o público final.

3. Dashboard:

Imagem no Figma




Figure 5: Figma

Imagens no Streamlit




Figure 6: Hora




Figure 7: Fornecedor




Figure 8: Pagamento




Figure 9: Dia da Semana

4. Conclusão

Este projeto foi uma aplicação prática de conceitos fundamentais de engenharia de dados, com foco em ETL, limpeza, organização e análise de um conjunto real de dados. Ao longo do processo, foi possível perceber como a qualidade dos dados impacta diretamente a confiabilidade dos resultados finais e a importância de transformar informações brutas em indicadores úteis para tomada de decisão.

A combinação entre pipeline, análise exploratória e dashboard reforça a proposta do projeto: demonstrar, de maneira simples e didática, como dados de mobilidade urbana podem ser utilizados para gerar insights relevantes. O resultado final mostra que mesmo um fluxo inicial de ETL pode gerar valor analítico significativo quando desenvolvido com organização e atenção à qualidade dos dados.